# Fab Copilot

## Phase 1 시스템 설계 사양서

Version 3.5

LLM: 향후 옵션화 예정 | Client GUI: ChatGPT-Style Interface

### 개정 이력

| 버전 | 날짜 | 변경 사항 | 작성자 |
|---|---|---|---|
| v2.2 | 2025-01 | Query Router, Dual-Gate, Telemetry 추가 | - |
| v3.0 | 2025-02 | Table Parsing, Image 전략, Embedding 평가, Latency, 보안, 캐시, Runbook | - |
| v3.1 | 2025-02 | 문서 참조 뷰어(Citation Pane) 추가, 전체 한글화 | - |
| v3.2 | 2025-02 | E2E 지연 3 분 확대, Latency 재배분, 타임아웃 처리 정책 | - |
| v3.3 | 2025-02 | 정밀 출처 인용, Ghost Citation 방지 Gate C, 인용 Hallucination 평가 | - |
| v3.4 | 2025-02 | BGE-M3/KURE 선택적 Embedding, Dual-Index 전환, 모델 비교 평가 | - |
| v3.5 | 2025-02 | Config 기반 LLM 서버 선택 (Ollama/HuggingFace TEI), 서버별 기본 Embedding 조합 (Ollama→Snowflake, TEI→BGE-M3), Hot-Reload | - |

| | | | |
|---|---|---|---|
| | | 전환 | |

# 1. 목적

## 1.1 Phase 1 목표

- 장비 매뉴얼 및 트러블슈팅 가이드 **고정밀 검색**
- 에러코드 기반 즉시 대응 및 해결책 제시
- **문서 근거 기반 응답** (Hallucination 최소화): 검색 결과 부족 시 **답변 거부 로직** 포함
- **문서 참조 뷰어(Citation Pane)**: 응답 내 인용 클릭 시 원문 PDF 자동 표시 및 해당 영역 하이라이트
- **종단간 응답 지연 목표**: P95 < 3 분 (180 초)

## 1.2 비범위 (Phase 1)

- 로그 분석 / 실시간 스트리밍 분석 (Phase 2)
- 멀티모달 이미지 인식 기반 트러블슈팅 (Phase 3)

# 2. 클라이언트 GUI 아키텍처 (ChatGPT 스타일)

GUI 는 ChatGPT 형식을 기본으로 하며, 현장 편의 기능과 **문서 참조 뷰어(Citation Pane)**를 추가한다.

## 2.1 UI 구조

### 2.1.1 좌측 사이드바

- 장비 선택기 (Equipment Selector): 모델/버전 드릴다운
- 대화 세션 목록 및 검색 히스토리
- **장비/문서 필터**: model_version, language, revision
- **즐겨찾기/북마크**: 자주 참조하는 답변 고정

### 2.1.2 메인 채팅 윈도우

- 사용자 메시지 (우측 정렬) / Fab Copilot 응답 (좌측 정렬)
- **인용(Citation) 클릭 시 우측 Citation Pane 에서 해당 PDF 페이지 자동 오픈 및 근거 영역 하이라이트**
- Code Block / Markdown Table / 이미지 팝업 뷰어 지원
- **인라인 피드백**: 답변별 좋아요/싫어요 + 코멘트

### 2.1.3 상단 바

- 현재 선택된 장비 및 모델 정보
- **검색 모드 토글**: Hybrid / Strict Grounded
- **문서 버전 정책 표시 / 응답 지연 인디케이터**

### 2.1.4 하단 입력 패널

- 프롬프트 입력창 및 파일 업로드 (PDF/이미지)
- **추천 질의어**: 에러코드 입력 시 연관 FAQ 추천
- **빠른 템플릿**: 원인/조치/주의사항/필요 정보 버튼

## 2.2 응답 포맷 (Strict)

Fab Copilot 응답은 다음 형식을 강제한다:

| # | 항목 | 설명 |
|---|---|---|
| 1 | 요약 | 조치 사항 1 줄 요약 |
| 2 | 상세 설명 | 단계별 해결 절차 (표/리스트 활용) |
| 3 | 참조 섹션 및 이미지 | 참조 섹션 제목 + 도면/사진 (클릭가능 링크) |

| | | |
|---|---|---|
| 4 | 출처 인용 | [DOC_ID-Chapter-Section-{Line:FromLine-ToLine}] 형식 정밀 인용 → 클릭 시 Citation Pane |
| 5 | 신뢰도 확인 | 근거 부족 시 "매뉴얼 내 정보 없음" + 추가 필요 입력 안내 |

## 2.3 문서 참조 뷰어 (Citation Pane) 상세 사양

**[NEW v3.1]** 응답 내 인용 링크 클릭 시 별도 Pane 에서 원문 PDF 를 열고 해당 근거 영역을 자동 선택/하이라이트하여 보여주는 기능.

### 2.3.1 레이아웃 구성

Chat Window 우측에 **접이식(Collapsible) Citation Pane** 배치. 기본은 접힘 상태, 인용 클릭 시 자동 펼쳐짐.

| 구성 요소 | 설명 |
|---|---|
| 전체 레이아웃 | 3 패널: Left Sidebar (20%) \| Main Chat (40~55%) \| Citation Pane (25~40%) |
| Citation Pane 위치 | Main Chat Window 우측, 접이식(Collapsible) |
| 기본 상태 | 접힘(Collapsed) → 인용 클릭 시 자동 펼쳐짐(Expanded) |
| 크기 조절 | 드래그로 Pane 폭 조절 가능 (min: 300px, max: 60%) |
| 모바일 대응 | 전체 화면 오버레이 모드, 스와이프로 닫기 |

### 2.3.2 인용 링크 동작 흐름

응답 내 **[MNL-2025-001-Ch3-S3.2.1-{Line:142-158}]** 클릭 시 동작:

1. 사용자가 응답 내 인용 링크 [DOC_ID-Chapter-Section-{Line:From-To}] 클릭
2. Citation Pane 자동 펼쳐짐 (Collapsed → Expanded)
3. 해당 문서 PDF 가 Citation Pane 내부에 로딩
4. **해당 페이지로 자동 스크롤** (PDF 의 해당 page 로 이동)
5. **근거 영역 자동 하이라이트**: 노란색 배경(#FFF3CD, opacity 0.4)으로 강조
6. 하이라이트 영역이 Pane 중앙에 오도록 **스크롤 위치 자동 조정**
7. 추가 인용 클릭 시 새 탭으로 열려 비교 가능

### 2.3.3 Citation Pane 내부 구성 요소

| 구성 요소 | 기능 | 상세 설명 |
|---|---|---|
| PDF 뷰어 영역 | 문서 렌더링 | pdf.js 기반 인라인 PDF 렌더러, 줄/페이지 단위 스크롤 |
| 하이라이트 오버레이 | 근거 영역 강조 | 반투명 노란색(#FFF3CD, opacity 0.4) 오버레이 |
| 문서 정보 헤더 | 메타데이터 표시 | 문서명, 버전(revision), 페이지, 섹션 정보바 |
| 페이지 네비게이션 | 페이지 이동 | 페이지 번호 입력 / 이전/다음 / 페이지 썸네일 |
| 확대/축소 | 줌 제어 | 25%~400% 범위, 도면/표 상세 확인용 |

| | | |
|---|---|---|
| 다중 인용 탭 | 복수 참조 관리 | 여러 인용 클릭 시 탭으로 관리, 탭 전환으로 비교 |
| 닫기/접기 버튼 | Pane 토글 | X 버튼 또는 Collapse 버튼으로 Pane 접기 |

### 2.3.4 하이라이트 매핑 방법

- **텍스트 근거**: chunk 생성 시 저장된 char_offset_start/end 좌표로 PDF 텍스트 레이어에서 영역 연산 → 오버레이 렌더링
- **표(Table) 근거**: 표의 bbox(bounding box) 좌표를 메타데이터에 저장, 해당 bbox 영역에 오버레이
- **이미지/도면 근거**: 이미지 bbox 좌표로 해당 영역 테두리 강조 표시
- **폴백(Fallback)**: char_offset 매핑 실패 시 페이지 전체 표시 + "정확한 위치 표시 불가" 안내

### 2.3.5 기술 구현 요구사항

| 항목 | 요구사항 |
|---|---|
| PDF 렌더링 엔진 | pdf.js (Mozilla) v4.x 이상, Canvas/SVG 렌더링 모드 지원 |
| 하이라이트 방식 | PDF 텍스트 레이어 위 반투명 div 오버레이 (#FFF3CD, opacity 0.4) |
| 좌표 저장 | chunk 메타데이터에 {doc_id, chapter, section, page, line_start, line_end, char_offset_start/end, bbox} 포함 |
| 응답 데이터 | citation_id 부여, {doc_id, chapter, section, line_range, page, highlight_coords, chunk_id} 포함 |
| 네트워크 최적화 | PDF 페이지 Lazy Loading, 클릭된 페이지만 우선 로드 |
| PDF 캐싱 | 최근 PDF 페이지 브라우저 캐시 (IndexedDB / Service Worker) |
| 접근성 | 키보드 네비게이션 지원, 하이라이트 영역 ARIA label 적용 |

### 2.3.6 사용자 시나리오 예시

**시나리오**: 엔지니어가 "에러코드 E-1023 원인과 조치 방법" 질의:

1. Fab Copilot 응답: "원인: 진공 누설... 조치: O-ring 교체 [MNL-2025-001-Ch3-S3.2.1-{Line:142-158}]"
2. 엔지니어가 [MNL-2025-001-Ch3-S3.2.1-{Line:142-158}] 클릭
3. Citation Pane 가 우측에서 자동 펼쳐짐
4. PDF 가 42 페이지로 자동 스크롤되어 표시
5. Section 3.2.1 "진공 누설 원인 및 O-ring 교체 절차" 영역이 노란색 하이라이트
6. 엔지니어가 확대하여 상세 도면 확인 가능
7. 추가 인용 클릭 시 새 탭으로 열려 비교 가능

### 2.3.7 응답 데이터 구조 (API)

Backend 에서 Frontend 로 전달되는 citations 배열 항목 구조:

- **citation_id**: 고유 식별자 (e.g., "cite_001")
- **doc_id / doc_title / revision**: 문서 식별 및 버전 정보
- **chapter**: 문서 내 Chapter 번호 (e.g., "Ch3")
- **section**: 섹션 번호 (e.g., "3.2.1")
- **page**: PDF 페이지 번호
- **line_range**: {시작 행, 끝 행} (e.g., {from: 142, to: 158}) — 출처 정밀 추적용 [NEW v3.4]
- **highlight_type**: "text" | "table" | "image"
- **highlight_coords**: text→{char_offset_start, char_offset_end}, table/image→{bbox: {x,y,w,h}} (pt)
- **chunk_id**: 참조 chunk 식별자
- **pdf_url**: PDF 파일 접근 경로 (내부 저장소 URL)
- **display_ref**: UI 표시용 포맷팅된 문자열 (e.g., "MNL-2025-001-Ch3-S3.2.1-{Line:142-158}") [NEW v3.4]

# 3. 시스템 전략 (Hybrid++)

검색 시스템은 의미론적 검색과 키워드 검색을 결합한 다층 하이브리드 방식을 채택한다.

## 3.1 핵심 구성 요소

| # | 구성 요소 | 목적 |
|---|---|---|
| 1 | Vector Search | 의미론적 유사도 검색 (문맥 이해) |
| 2 | BM25 키워드 검색 | 에러코드, 부품번호 등 고유명사 정밀 매칭 |
| 3 | 기술 동의어 사전 | 현장 약어 및 기술 용어 매핑 (Vv, Press, P 등) |
| 4 | Re-ranking (Cross Encoder) | 검색 결과 재정렬로 정확도 향상 |
| 5 | Query Router (의도 기반) | 질의 유형 분기 및 가중치/필터 최적화 |
| 6 | Diversity Selection (MMR) | 상위 결과 중복 제거 및 근거 다양성 확보 |
| 7 | 결과 캐시 레이어 | 빈번 질의(에러코드) 캐시로 응답 지연 감소 |

## 3.2 Query Router (의도 기반)

| Intent | 전략 | 예시 질의 |
|---|---|---|
| error | Error Lookup + BM25 가중치↑ | "에러 E-1023 발생" |
| procedure | 절차/작업 순서 섹션 가중치↑ | "헤드 클리닝 절차" |
| part | 부품번호/소모품 + 정규화 룰 | "O-ring P/N 12345" |
| definition | 용어/Glossary 섹션 우선 | "EPD 란 무엇인가?" |
| spec | 스펙/한계치/표 chunk 우선 | "압력 스펙 범위" |
| comparison | 복수 문서 교차 참조 + 버전 비교 | "Rev.A 와 Rev.B 차이점" |
| general | 일반 하이브리드 검색 | "슬러리 시스템 작동 원리" |

## 3.3 결과 캐시 전략

- **캐시 범위**: (equipment, intent, normalized_query) 튜플 단위
- **TTL**: 24 시간 또는 문서 revision 업데이트 시점 중 더 짧은 쪽
- **무효화**: 문서 재인덱싱 시 자동 / 관리자 API 수동 Purge
- **캐시 적중률 목표**: 배포 3 개월 내 error 유형 > 30%

# 4. 문서 전처리 전략

## 4.1 구조 기반 청킹 (Table-Aware)

- 표 파싱: 매뉴얼 내 표 데이터를 Markdown 으로 변환, 구조 보존
- 이미지 앵커링: 도면/사진 위치 정보를 메타데이터에 귀속
- 계층 구조 유지: Chapter > Section > Procedure > Error Code

## 4.2 표 파싱 파이프라인

| 도구 | 적합 대상 | 제한사항 | 폴백(Fallback) |
|---|---|---|---|
| Camelot (lattice) | 격자선 있는 표 | 경계선 없는 표 실패 | stream 모드 전환 |
| Camelot (stream) | 경계선 없는 표 | 복잡 레이아웃 정확도↓ | 수동 주석 |
| Tabula | 단순 표 | 셀 병합 처리 어려움 | 후처리 스크립트 |
| Google Document AI | 복잡 다중 스팬 표 | 클라우드 의존, 비용 | On-prem OCR |

## 4.3 청킹 규칙

- Procedure/Cause/Action chunk: **10~20% overlap**
- 각 chunk 에 **parent_context** (상위 섹션 요약 1~2 줄) 포함
- 표 chunk: **표 제목 + 컬럼 헤더 + 단위** 필수 포함
- **최대**: 512 토큰 / **최소**: 64 토큰
- **Citation Pane 연동용**: 각 chunk 에 {doc_id, chapter, section, page, line_start, line_end, char_offset_start/end, bbox} 포함 필수 [v3.1+v3.4]

## 4.4 메타데이터 필드

| 필드 | 설명 | 구분 |
|---|---|---|
| equipment | 장비명/식별자 | 핵심 |
| doc_type | 문서 유형 | 핵심 |
| chapter/section/page | 문서 내 계층적 위치 | 핵심 |
| model_version | 장비 세부 버전별 구분 | 핵심 |
| language | 국문/영문 필터링 | 핵심 |
| last_updated | 최신 개정일 | 핵심 |

| | | |
|---|---|---|
| doc_id/revision | 문서 ID 및 개정 코드 | 확장 |
| is_superseded | 대체 여부 | 확장 |
| option_kit | 적용 옵션/키트 | 확장 |
| chunk_type | text/table/image_ref/procedure | 확장 |
| highlight_coords | {doc_id, chapter, section, page, line_start, line_end, char_offset_start/end, bbox} [v3.1+v3.4] | 핵심 |

# 5. 검색 및 생성 흐름

1. 사용자 질의 입력
2. Query Parser: 동의어 확장, 에러코드/부품번호 추출
3. 캐시 확인: cache hit 시 8 단계로 건너뛰
4. Query Router: intent 분류
5. Hybrid Search: Vector + BM25 + Structured Filter
6. Threshold Filtering + Re-ranking (Cross Encoder) + MMR
7. **LLM 생성**: 근거 기반 응답 + 인용 + **Citation Pane 연동 데이터(highlight_coords)**
8. 후처리: 인용 포맷팅, 신뢰도 확인, 캐시 업데이트

## 5.1 Dual-Gate 응답 정책

- **Gate A (검색 신뢰도)**: hybrid 점수 + intent 적합도로 후보 문서 품질 평가
- **Gate B (근거 신뢰도)**: 실제 인용 가능한 근거 존재 여부로 최종 결정
- **Gate C (인용 검증)**: 응답 내 모든 인용이 실제 존재하는 문서/페이지/섹션/행 번호인지 후처리 단계에서 검증 [NEW v3.4]

거부 시: "근거 부족" / "추가 필요 정보" 안내 / **대안 질의 추천**

### 5.1.1 유령 인용(Ghost Citation) 방지 [NEW v3.4]

LLM 이 실제 존재하지 않는 문서, 페이지, 섹션, 행 번호를 응답에 포함하는 현상을 방지하기 위한 검증 체계:

- **문서 ID 검증**: 응답의 doc_id 가 실제 인덱싱된 문서 DB 에 존재하는지 확인
- **페이지 범위 검증**: 인용된 페이지 번호가 해당 문서의 실제 총 페이지 수 이내인지 확인
- **섹션/Chapter 검증**: 인용된 Chapter, Section 번호가 문서 목차(TOC)와 일치하는지 확인
- **행 번호 검증**: line_range 의 from/to 가 해당 페이지 내 실제 행 수 범위 이내인지 확인
- **내용 일치 검증**: 인용된 영역의 텍스트가 실제 chunk 내용과 의미적으로 일치하는지 검증
- **검증 실패 시 처리**: 해당 인용을 응답에서 제거하고 "출처 확인 불가" 표시, 텔레메트리에 기록

## 5.2 응답 지연 예산

| 단계 | 목표 (P95) | 비고 |
|---|---|---|
| Query 파싱 + 라우팅 | < 500 ms | 경량 분류기 + 정규식 |
| Embedding 생성 | < 1,000 ms | 배치 최적화 추론 |
| Hybrid Search + Filter | < 2,000 ms | Elasticsearch/Qdrant 복합, 복잡 필터 허용 |
| Re-ranking | < 3,000 ms | Top-50 후보까지 확장 가능 |

| | | |
|---|---|---|
| LLM 생성 | < 160,000 ms | 복잡 추론/다중 문서 종합 허용, 스트리밍 첫 토큰 < 3,000 ms |
| 후처리 + Citation 데이터 | < 500 ms | 인용 포맷팅 + highlight_coords |
| 전체 (E2E) | < 180,000 ms (3 분) | P95 목표 |

## 5.3 응답 타임아웃 처리 정책

**[NEW v3.3]** 정해진 시간 내 응답이 완료되지 않을 경우, 사용자에게 적절한 알람을 제공하고 시간 제한을 재조정할 수 있는 옵션을 제공한다.

### 5.3.1 타임아웃 단계별 알람 정책

| 단계 | 트리거 조건 | 사용자 알람 내용 |
|---|---|---|
| 진행 상황 안내 | E2E 30 초 경과 | "검색 및 분석 진행 중입니다..." 프로그레스바 + 단계 표시 |
| 지연 경고 | E2E 60% 소진 (약 1 분 48 초) | "예상보다 시간이 소요되고 있습니다" + 대기/취소 버튼 |
| 타임아웃 임박 | E2E 90% 소진 (약 2 분 42 초) | "응답 시간 제한에 근접합니다" + 시간 연장/취소 선택지 제공 |
| 타임아웃 발생 | E2E 제한 초과 (3 분) | "응답 시간을 초과했습니다" + 재시도/시간 재조정/질의 단순화 옵션 |

### 5.3.2 사용자 시간 재조정 옵션

타임아웃 발생 또는 임박 시 사용자에게 다음 옵션을 제공한다:

- **시간 연장**: 현재 제한의 2 배로 연장 (3 분 → 6 분), 최대 10 분까지 허용
- **질의 단순화 제안**: "질의를 더 구체적으로 좌혀보시겠습니까?" + 예시 제시
- **부분 응답 제공**: 타임아웃 시점까지 생성된 부분 결과를 먼저 표시하고 "계속 생성" 버튼 제공
- **취소 및 재시도**: 현재 요청 취소 후 수정된 질의로 재시도
- **기본 시간 제한 변경**: 사용자 설정에서 기본 타임아웃을 1 분/3 분/5 분/10 분 중 선택 가능

### 5.3.3 UI 표시 요구사항

- **프로그레스 인디케이터**: 응답 생성 중 현재 단계(검색/리랭킹/생성) 및 경과 시간 실시간 표시
- **알람 팝업**: 비차단적(non-blocking) 팝업으로 표시, 작업 흐름 방해 최소화
- **소리 알람**: 선택적 음향 알림 (현장 환경에서 다른 작업 중 알림 수신 가능)

- **알람 이력**: 타임아웃 발생 이력을 사이드바에 기록, 향후 시간 설정 참고용

### 5.3.4 관리자 설정

- **전역 기본 타임아웃**: 관리자가 시스템 전체 기본값 설정 (1 분/3 분/5 분/10 분)
- **장비별 타임아웃**: 문서 복잡도에 따라 장비 유형별 다른 타임아웃 설정 가능
- **최대 허용 시간**: 사용자가 연장할 수 있는 최대 시간 상한 설정 (기본: 10 분)
- **타임아웃 통계 대시보드**: 타임아웃 발생 빈도, 평균 응답 시간, 장비/intent 별 분포 모니터링

# 6. LLM 프롬프트 규칙

- **No Source, No Answer**: 문서 기반 응답만 허용, 추측 금지
- "원인 분석 → 매뉴얼 근거 확인 → 해결책" 흐름, 출력은 근거 중심
- 모든 응답에 **정밀 출처 인용** 필수: [DOC_ID-Chapter-Section-{Line:FromLine-ToLine}] 형식 [v3.4]
- 수치, 단위(°C, MPa 등) 및 고유명사 원문 유지
- 문서 충돌 시 revision/last_updated 기준 우선순위 명시 + 충돌 사실 안내
- 사용자 질의 언어와 동일한 언어로 응답
- 표 데이터 관련 응답 시 원본 구조 유지하여 부분 재현
- **모든 인용에 citation_id, highlight_coords, line_range, display_ref 포함 필수 [v3.1+v3.4]**
- **유령 인용(Ghost Citation) 절대 금지**: 검색된 chunk 에 존재하지 않는 문서 ID, 페이지, 섹션, 행 번호를 응답에 포함하지 말 것 [NEW v3.4]

# 7. Embedding 모델 선택 및 평가 프레임워크

## 7.1 선택 가능 모델

시스템은 Config 에서 선택한 LLM 서버에 따라 기본 Embedding 이 자동 지정되며, 수동 변경도 가능하다:

| 모델 | 특성 | 기본 서버 | 강점 |
|---|---|---|---|
| Snowflake Arctic Embed | 경량 고성능 Embedding | Ollama (기본) | Ollama 네이티브 지원, 빠른 추론 |
| BGE-M3 | 다국어, Dense+Sparse+ColBERT | HuggingFace TEI (기본) | 교차언어 검색 우수, 영문 매뉴얼 대응 |
| KURE | 한국어 특화 Retrieval | 수동 지정 | 한국어 기술 문서 정확도 우수 |

## 7.2 모델 전환 아키텍처 [NEW v3.4]

Embedding 모델 전환 시 서비스 중단 없이 전환할 수 있는 구조:

- **Embedding Abstraction Layer**: 모델 변경 시 검색/인덱싱 코드 변경 없이 Config 설정만으로 전환
- **Dual-Index 전략**: 활성 Embedding 인덱스와 대기 인덱스를 병렬 유지 (Snowflake/BGE-M3/KURE 중 2 개)
- **전환 절차**: 새 모델로 전체 문서 재인덱싱 → 평가 테스트 통과 → 활성 인덱스 전환 → 구 인덱스 보관(rollback 용)
- **자동 폐백**: 전환 후 Recall@10 저하 감지 시 이전 모델로 자동 복귀
- **하이브리드 모드 (향후)**: 두 모델 결과를 결합하여 검색 품질 극대화 (Phase 1.5 검토)

## 7.3 평가 기준

두 모델을 동일 기준으로 비교 평가하여 최적 모델을 선정한다:

- **평가 지표**: Recall@10, MRR@10, NDCG@10 (intent 별 분리 평가)
- **교차언어 평가**: 한국어 질의 → 영문 문서, 영어 질의 → 한국어 문서 각각 측정
- **추론 지연**: 두 모델의 P95 추론 시간 비교 (Latency Budget 1,000ms 이내)
- **도메인 적합성**: 반도체 장비 기술 용어/약어 검색 정확도 (e.g., "Vv leak", "CF 교체")
- **선정 기준**: 장비별 Recall@10 가중 평균이 더 높은 모델을 기본값으로 선정, 관리자가 장비별 개별 지정 가능

## 7.4 Fine-Tuning 기준

- Recall@10 < 80% 시 fine-tuning 진행
- Fine-tuning 데이터: 최소 5,000 개 positive pair

# 8. 기술 동의어 사전 관리

- Vacuum → Vac, Vv, V/V | Pressure → Press, P, PRESS | Carrier Film → CF, Membrane
- 초기 구축 → 분기별 리뷰 → 피드백 기반 즉시 추가 → Git 버전 관리

# 9. 권장 기술 스택 (On-Prem)

| 계층 | 주선택 | 대안 |
|---|---|---|
| 검색 엔진 | Elasticsearch 8.x | OpenSearch 2.x |
| Vector DB | Qdrant (on-prem, HNSW) | Weaviate / Milvus |
| LLM 서빙 서버 | Ollama / HuggingFace TEI (Config 선택) [NEW v3.5] | 설정 파일로 전환, 두 서버 동시 운영 가능 |
| Embedding | Ollama→Snowflake / TEI→BGE-M3 (기본 조합) [NEW v3.5] | KURE 등 추가 모델 Config 으로 변경 가능 |
| Re-ranker | BGE-Reranker-v2-M3 | Cross-encoder/ms-marco |
| 캐시 | Redis 7.x | In-memory LRU |
| PDF 뷰어 | pdf.js v4.x (Citation Pane) | PSPDFKit / PDF Viewer |
| 모니터링 | Prometheus + Grafana | ELK Stack |

## 9.1 LLM/Embedding 서버 구성 관리 [NEW v3.5]

Config 파일(YAML/JSON)을 통해 LLM 서빙 서버와 Embedding 모델을 선택하고, 서비스 재시작 없이 전환할 수 있는 구조:

### 9.1.1 LLM 서빙 서버 선택

| 서버 | 특성 | 기본 Embedding | 적합 시나리오 |
|---|---|---|---|
| Ollama | 로컬 배포 용이, 다양한 GGUF 모델 지원 | Snowflake Arctic Embed | 빠른 PoC, 경량 배포, GPU 자원 제한 환경 |
| HuggingFace TEI | 고성능 추론 서버, 배치 최적화 | BGE-M3 | 대규모 배포, 다국어 지원, 고품질 추론 |

**Config 예시** (YAML):

- **llm_server**: ollama | huggingface_tei
- **llm_model**: 서버별 사용할 모델명 (e.g., gemma3:12b, mistral-7b-instruct)

- **embedding_model**: 서버별 기본값 자동 적용 (수동 오버라이드 가능)
- **embedding_server**: llm_server 설정과 동일 서버 사용 (별도 지정 가능)

### 9.1.2 기본 조합 (Default Pairing)

| Config 값 | LLM 서버 | Embedding 모델 | 비고 |
|---|---|---|---|
| llm_server: ollama | Ollama | Snowflake Arctic Embed | 경량 배포 최적화 조합 |
| llm_server: huggingface_tei | HuggingFace TEI | BGE-M3 | 고품질 다국어 최적화 조합 |

기본 조합 외에도 Config 에서 embedding_model 을 수동 지정하여 KURE 등 다른 모델로 변경 가능하다.

### 9.1.3 전환 절차 및 제약사항

- **Hot-Reload**: Config 변경 시 서비스 재시작 없이 적용 (진행 중 요청은 기존 설정으로 완료)
- **Embedding 모델 변경 시**: 전체 문서 재인덱싱 필요 (Dual-Index 전략으로 무중단 전환, 7.2 장 참조)
- **LLM 서버 변경 시**: 재인덱싱 불필요, 즉시 전환 가능
- **호환성 검증**: 전환 전 선택한 서버에서 모델 가용 여부 자동 확인 (미설치 시 에러 반환)
- **폐백**: 선택한 서버 응답 없을 시 대체 서버로 자동 전환 (Config 에 fallback_server 지정 시)

# 10. 보안 및 접근 제어

- 기업 SSO (LDAP/SAML) 연동 / **RBAC**: Operator/Engineer/Admin
- 장비별 문서 접근 제한 / 세션 타임아웃: 유휴 30 분, 최대 8 시간
- 모든 API TLS 1.3 / 저장 시 AES-256 암호화 / 질의 로그 PII 제거
- **에어갭(Air-gapped) 배포** 옵션 / 감사 추적 (모든 질의, 문서 접근, 관리자 작업)

# 11. 품질 및 모니터링

## 11.1 검색 텔레메트리 (Phase 1 최소)

- Query 원문 + intent + 추출된 error_code / part_no
- Top-k 문서: doc_id / page / score / rerank_score
- 최종 인용 chunk id / page / 거부 사유
- 사용자 피드백 (좋아요/싫어요)
- **단계별 지연 시간** + **캐시 hit/miss**
- **Citation Pane 사용 지표**: 인용 클릭 횟수, Pane 체류 시간, 확대 사용 빈도 [NEW v3.1]
- **타임아웃 지표**: 타임아웃 발생 횟수, 사용자 시간 연장/취소/단순화 선택 비율, 장비/intent 별 타임아웃 분포 [NEW v3.4]

## 11.2 평가 (Phase 1.5)

- RAGAS 프레임워크 활용 검색 품질 정량 평가
- Ground Truth 데이터셋 Phase 1 과 병행 구축 (장비별 100 개+ 트리플)

### 11.2.1 인용 Hallucination 평가 [NEW v3.4]

실제 존재하지 않는 문서/페이지/섹션/행 번호를 인용하는 **유령 인용(Ghost Citation)** 문제를 평가하기 위한 테스트 체계:

| 평가 항목 | 방법 및 기준 |
|---|---|
| 문서 ID 존재성 | 응답의 모든 doc_id 가 문서 DB 에 실제 존재하는지 자동 검증. 목표: 불일치율 0% |
| 페이지 번호 유효성 | 인용된 page 가 해당 문서의 총 페이지 수 이내인지 확인. 목표: 불일치율 0% |
| 섹션/Chapter 일치 | 인용된 chapter/section 이 문서 TOC 와 일치하는지 확인. 목표: 불일치율 < 2% |
| 행 범위 유효성 | line_range 의 from/to 가 해당 페이지 실제 행 수 이내인지 확인. 목표: |

| | |
|---|---|
| | 불일치율 < 3% |
| 내용 일치성 | 인용 영역 텍스트가 실제 chunk 내용과 의미적으로 일치하는지 LLM-as-Judge. 목표: F1 > 90% |
| 비존재 문서 유도 테스트 | 존재하지 않는 에러코드/부품번호 질의 시 거부 여부 확인. 목표: 거부율 100% |
| 부분 조작 테스트 | 실제 문서의 수치/단위를 변조한 질의 시 원문 근거로 정정 여부. 목표: 정정율 > 95% |

**평가 실행 방법**: Ground Truth 데이터셋에 상기 항목별 테스트 케이스를 포함하고, CI/CD 파이프라인에 자동화된 회귀 테스트로 통합. 모델/프롬프트 변경 시 반드시 재실행.

## 11.3 운영 Runbook

- 문서 재인덱싱: 트리거 조건, 예상 다운타임, 롤백 절차
- 모델 업데이트: A/B 테스트 프로토콜
- 캐시 Purge / 동의어 사전 업데이트 배포 절차
- 장애 대응: 검색 품질 저하 알림 에스컬레이션 경로

# 12. 개발 로드맵

## 12.1 Phase 1 (v3.5)

- 문서 전처리: 표 파싱 + 이미지 앵커링 + **highlight_coords 저장**
- 기술 동의어 사전 구축 + 유지보수 프로세스
- Hybrid 검색: Vector + BM25 + Query Router + Re-ranking + MMR
- Embedding 모델 평가 및 선정 / 결과 캐시 레이어
- ChatGPT 스타일 UI + **Citation Pane (pdf.js 기반 문서 참조 뷰어)** [NEW v3.1]
- Grounded QA + Dual-Gate 응답 정책
- **응답 타임아웃 처리: 단계별 알람 + 사용자 시간 재조정 UI** [NEW v3.4]
- 텔레메트리 + Citation Pane 사용 지표 추적
- RBAC + TLS + 암호화 / Ground Truth 병행 구축 / 운영 Runbook v1

## 12.2 Phase 1.5

- RAGAS 기반 검색 품질 평가 및 최적화
- Embedding fine-tuning (Recall@10 < 80% 시)
- 이미지 OCR 캡션 추출 + 그림 교차 참조 파싱
- A/B 테스트 프레임워크

## 12.3 Phase 2

- 로그 분석 통합 + 실시간 피드백 루프
- 예측 유지보수 알림 연계 / 다장비 교차 참조 검색

## 12.4 Phase 3

- 멀티모달 인식 기반 트러블슈팅 (사진/영상 입력)
- AR 오버레이 유지보수 절차 / 지식 그래프 구축

# A. 부록: 용어 정의

| 용어 | 정의 |
|---|---|
| RAG | Retrieval-Augmented Generation |
| BM25 | Best Matching 25 – 확률적 키워드 검색 알고리즘 |
| MMR | Maximal Marginal Relevance – 다양성 기반 결과 선택 |
| HNSW | Hierarchical Navigable Small World – 근사 이웃 인덱스 |
| EPD | End Point Detection – 반도체 장비 공정 종점 감지 |
| CMP | Chemical Mechanical Planarization |
| RAGAS | Retrieval-Augmented Generation Assessment 프레임워크 |
| RBAC | Role-Based Access Control – 역할 기반 접근 제어 |
| Citation Pane | 응답 내 인용 클릭 시 원문 PDF 표시/하이라이트 패널 [NEW v3.1] |
| pdf.js | Mozilla 오픈소스 PDF 렌더링 라이브러리 |